

## Clase 2

### 1. Introducción al Análisis de Algoritmos

#### 1.1 Importancia del Análisis de Algoritmos

El análisis de algoritmos es una disciplina esencial en la informática teórica, enfocada en la evaluación de la eficiencia de un algoritmo en términos de tiempo de ejecución y uso de recursos, como la memoria. Esta evaluación es crítica para el desarrollo de software eficiente y escalable, permitiendo a los desarrolladores seleccionar los algoritmos más adecuados para resolver problemas en diferentes contextos.

Como señalan Cormen et al. (2001), "El análisis de algoritmos es una parte fundamental de la informática teórica. Se trata de evaluar la eficiencia de un algoritmo en términos de tiempo de ejecución y uso de memoria". Este tipo de análisis es esencial no solo para entender el comportamiento de los algoritmos con datos de diferentes tamaños, sino también para optimizar los recursos computacionales en sistemas en tiempo real, bases de datos, procesamiento de grandes volúmenes de información, y más.

#### 1.2 Métodos de Análisis

El análisis de algoritmos se puede llevar a cabo mediante dos enfoques principales:

- **Análisis Teórico:** Este enfoque se basa en evaluar el algoritmo sin necesidad de implementarlo. Se estudia su estructura y se cuenta el número de operaciones básicas que realiza en función del tamaño de la entrada,  $n$ . Este tipo de análisis frecuentemente utiliza notaciones asintóticas, como la notación Big O, para describir el comportamiento del algoritmo a medida que el tamaño de la entrada aumenta.

Según Luis Joyanes Aguilar (2008), "El análisis teórico permite predecir el comportamiento de un algoritmo para entradas de datos de diferentes tamaños, centrándose en el término que más influye en el crecimiento de las operaciones a medida que crece el tamaño de la entrada".

- **Análisis Empírico:** Este enfoque implica la implementación del algoritmo y la medición de su rendimiento en un entorno de prueba real. Aunque ofrece resultados precisos para casos específicos, su aplicabilidad para prever el comportamiento del algoritmo en todos los escenarios posibles es limitada. Unai López de la Fuente (2018) destaca que "El análisis empírico es útil para verificar la eficiencia teórica del algoritmo en condiciones reales, pero no siempre puede generalizarse a diferentes contextos o tamaños de entrada".

#### 1.3 Factores a Considerar en el Análisis

El análisis de un algoritmo tiene en cuenta varios factores críticos:

1. **Tiempo de Ejecución:** Es el tiempo necesario para ejecutar el algoritmo, generalmente expresado en función del tamaño de la entrada  $n$ . Este tiempo puede variar dependiendo de si se considera el mejor caso, el caso promedio o el peor caso.

Según Gustavo López et al. (1998), "El tiempo de ejecución es un factor clave

en la evaluación de la eficiencia de un algoritmo, especialmente en aplicaciones donde el rendimiento es crucial".

2. **Uso de Memoria:** Corresponde a la cantidad de memoria que el algoritmo requiere durante su ejecución. Un algoritmo que utiliza menos memoria es generalmente preferible, especialmente en sistemas con recursos limitados.
3. **Simplicidad:** Un algoritmo debe ser fácil de entender y mantener. La simplicidad también puede contribuir a la reducción de errores en la implementación.
4. **Escalabilidad:** Un buen algoritmo debe poder manejar un aumento en el tamaño de la entrada de manera eficiente, sin un incremento desproporcionado en el tiempo de ejecución o el uso de memoria.  
Joyanes Aguilar (2008) subraya que "La escalabilidad es una característica esencial de los algoritmos modernos, especialmente en aplicaciones que manejan grandes volúmenes de datos".

## 1.4 Tipos de Análisis

El análisis de algoritmos se clasifica comúnmente en tres tipos, según el escenario considerado:

- **Análisis del Mejor Caso:** Evalúa el comportamiento del algoritmo en la situación más favorable. Aunque útil, este análisis no suele ser representativo del rendimiento general del algoritmo en condiciones normales de operación.
- **Análisis del Caso Promedio:** Considera el comportamiento del algoritmo en un escenario promedio, teniendo en cuenta todas las posibles entradas y su probabilidad. Este tipo de análisis es complejo pero es el más representativo de la experiencia diaria con un algoritmo.
- **Análisis del Peor Caso:** Se enfoca en el escenario más desfavorable para el algoritmo, es decir, el mayor tiempo de ejecución posible para cualquier entrada de tamaño  $n$ . Este análisis es crucial para asegurar que el algoritmo funcione dentro de límites aceptables en todas las circunstancias.  
Cormen et al. (2001) explican que "El análisis del peor caso es especialmente importante en aplicaciones críticas donde la predictibilidad del tiempo de ejecución es esencial".

## 1.5 Importancia del Peor Caso en el Análisis

El análisis del peor caso es de particular importancia en sistemas críticos, como en software de control de tráfico aéreo, sistemas bancarios, y cualquier otra aplicación donde el tiempo de respuesta debe garantizarse incluso en las condiciones más adversas.

Luis Joyanes Aguilar (2008) afirma que "El análisis del peor caso proporciona una estimación conservadora del tiempo de ejecución de un algoritmo, lo que es crucial en aplicaciones donde la seguridad y la fiabilidad son primordiales".

## 1.6 Conclusión

El análisis de algoritmos es una herramienta indispensable en el desarrollo de software eficiente y escalable. Comprender cómo un algoritmo utiliza recursos como el tiempo y la memoria permite a los desarrolladores tomar decisiones informadas sobre qué

algoritmos son más adecuados para diferentes tareas y condiciones de operación. Este conocimiento es fundamental para mejorar la eficiencia y optimizar los sistemas informáticos, permitiendo que manejen de manera efectiva volúmenes crecientes de datos y complejidad.

## 2. Notación Big O

### 2.1 Introducción a la Notación Big O

La notación Big O es una herramienta matemática utilizada para describir la eficiencia de un algoritmo en términos de su tiempo de ejecución o uso de memoria en función del tamaño de la entrada, denotado comúnmente como  $n$ . Es una de las notaciones asintóticas más importantes en el análisis de algoritmos, ya que proporciona una forma de expresar cómo el tiempo de ejecución de un algoritmo crece a medida que aumenta el tamaño de la entrada, centrándose en el comportamiento a largo plazo y en el término de mayor crecimiento.

Según Cormen et al. (2001), "La notación Big O describe cómo el tiempo de ejecución de un algoritmo crece en relación con el tamaño de la entrada  $n$ . Esta notación se centra en el término de mayor crecimiento, ignorando constantes y términos de menor importancia". Esto significa que Big O nos permite hacer una estimación general del comportamiento de un algoritmo, sin preocuparnos por los detalles específicos de implementación o las variaciones menores en el tiempo de ejecución.

### 2.2 Definición Formal

Formalmente, la notación Big O se define de la siguiente manera:

Un algoritmo tiene una complejidad  $O(f(n))$  si existe un número positivo  $c$  y un valor  $n_0$  tal que para todo  $n \geq n_0$ , el tiempo de ejecución  $T(n)$  del algoritmo está acotado por  $c \cdot f(n)$ . En otras palabras:

$$T(n) \leq c \cdot f(n) \quad \text{para todo } n \geq n_0$$

Donde:

- $T(n)$  es la función que describe el tiempo de ejecución del algoritmo en función del tamaño de la entrada  $n$ .
- $f(n)$  es una función que representa la complejidad del algoritmo (por ejemplo,  $n$ ,  $n^2$ ,  $\log n$ ).
- $c$  es una constante positiva.
- $n_0$  es el valor a partir del cual la desigualdad se mantiene.


### 2.3 Propiedades de la Notación Big O

1. **Focalización en el Término Dominante:** La notación Big O se concentra en el término de mayor crecimiento en la función de tiempo de ejecución, ya que este término domina el comportamiento del algoritmo para valores grandes de  $n$ .

2. **Ignora Constantes y Términos de Menor Importancia:** La notación Big O no toma en cuenta las constantes multiplicativas ni los términos de menor importancia, porque estos no afectan significativamente el crecimiento de la función para valores grandes de  $n$ .
3. **Comparación de Algoritmos:** Big O permite comparar la eficiencia de diferentes algoritmos de manera más sencilla y objetiva. Por ejemplo, un algoritmo con complejidad  $O(n)$  es más eficiente que uno con complejidad  $O(n^2)$  para grandes valores de  $n$ , ya que el tiempo de ejecución crece más lentamente.

Unai López de la Fuente (2018) señala que "La capacidad de comparar algoritmos utilizando la notación Big O es fundamental para seleccionar el mejor enfoque para un problema dado, especialmente cuando se trabaja con grandes volúmenes de datos".

## 2.4 Ejemplos Comunes de Complejidad Big O



- **$O(1)$  - Tiempo Constante:** El tiempo de ejecución del algoritmo no depende del tamaño de la entrada. Un ejemplo clásico es el acceso a un elemento de un array por su índice.
- **$O(\log n)$  - Tiempo Logarítmico:** El tiempo de ejecución crece logarítmicamente en relación con el tamaño de la entrada. Un ejemplo es la búsqueda binaria en un array ordenado.
- **$O(n)$ - Tiempo Lineal:** El tiempo de ejecución crece linealmente con el tamaño de la entrada. Un ejemplo es la búsqueda lineal en un array no ordenado.
- **$O(n \log n)$  - Tiempo Log-Linear:** El tiempo de ejecución crece a una tasa que es el producto de  $n$  y  $\log n$ . Ejemplos incluyen algoritmos de ordenamiento eficientes como Merge Sort y Quick Sort.
- **$O(n^2)$  - Tiempo Cuadrático:** El tiempo de ejecución crece proporcionalmente al cuadrado del tamaño de la entrada. Un ejemplo es el algoritmo de ordenamiento burbuja (Bubble Sort).
- **$(2^n)$ - Tiempo Exponencial:** El tiempo de ejecución crece exponencialmente en función del tamaño de la entrada. Este tipo de complejidad es típico de algoritmos que resuelven problemas NP-completos.

## 2.5 Aplicación Práctica de la Notación Big O

Entender y aplicar la notación Big O es crucial para la selección y optimización de algoritmos en el desarrollo de software. En la práctica, un desarrollador debe considerar la complejidad de los algoritmos disponibles y seleccionar el más eficiente para la tarea específica, teniendo en cuenta no solo el tiempo de ejecución, sino también el contexto en el que se utilizará el algoritmo.

Luis Joyanes Aguilar (2008) subraya que "La notación Big O no solo es una herramienta teórica, sino que tiene una aplicación práctica directa en la ingeniería de software, donde la eficiencia y la optimización de recursos son esenciales".

## 2.6 Conclusión

La notación Big O es una herramienta fundamental para describir y comparar la eficiencia de los algoritmos. Al centrarse en el término de mayor crecimiento y excluir constantes y términos de menor importancia, Big O permite a los desarrolladores y científicos de la computación entender cómo escalará un algoritmo con entradas más grandes, facilitando la toma de decisiones informadas sobre qué algoritmo es más adecuado para un problema dado.

## 3. Análisis del Peor Caso

### 3.1 Introducción al Análisis del Peor Caso

El análisis del peor caso es un enfoque fundamental en la evaluación de algoritmos, ya que se enfoca en el escenario más desfavorable posible. Este tipo de análisis es crucial para garantizar que un algoritmo funcione dentro de límites aceptables, incluso en las condiciones más adversas. En muchas aplicaciones prácticas, como sistemas en tiempo real o software crítico, es esencial conocer y mitigar los riesgos asociados con el tiempo de ejecución máximo que un algoritmo puede requerir.

Cormen et al. (2001) describen el análisis del peor caso como "el estudio del mayor tiempo de ejecución posible para cualquier entrada de tamaño  $n$ ", lo cual permite a los desarrolladores prepararse para las situaciones más extremas que un algoritmo podría enfrentar.

### 3.2 Importancia del Peor Caso

El análisis del peor caso es particularmente relevante en contextos donde el tiempo de respuesta debe ser garantizado, independientemente de la variabilidad en los datos de entrada. Por ejemplo, en un sistema de control de tráfico aéreo, el tiempo de respuesta del software debe mantenerse dentro de ciertos límites estrictos para evitar situaciones peligrosas. En este caso, conocer el peor caso ayuda a diseñar sistemas que sean seguros y confiables.

Luis Joyanes Aguilar (2008) enfatiza que "El análisis del peor caso proporciona una estimación conservadora del tiempo de ejecución de un algoritmo, lo que es crucial en aplicaciones donde la seguridad y la fiabilidad son primordiales".

## 3.3 Ejemplos de Análisis del Peor Caso

Veamos cómo se aplica el análisis del peor caso a algunos algoritmos comunes, junto con sus implementaciones en Python:

### Búsqueda Lineal

- **Descripción:** La búsqueda lineal es un algoritmo simple que recorre una lista de elementos para encontrar uno que coincida con el objetivo. Se examina cada elemento en secuencia hasta que se encuentra el objetivo o se llega al final de la lista.
- **Peor Caso:** Ocurre cuando el elemento buscado está al final de la lista o no está presente en absoluto. En este escenario, el algoritmo debe recorrer todos los elementos, resultando en un tiempo de ejecución  $O(n)$ , donde  $n$  es el número de elementos en la lista.

```
def busqueda_lineal(lista, objetivo):  
    for i in range(len(lista)):  
        if lista[i] == objetivo:  
            return i # Elemento encontrado  
    return -1 # Elemento no encontrado  
  
# Ejemplo de uso  
lista = [1, 2, 3, 4, 5]  
objetivo = 5 # Peor caso: el elemento está al final de la lista  
resultado = busqueda_lineal(lista, objetivo)  
print("Índice del objetivo:", resultado)
```

En este ejemplo, el peor caso ocurre cuando el elemento buscado (5) está en la última posición de la lista. El algoritmo debe recorrer toda la lista para encontrarlo, lo que representa un tiempo de ejecución  $O(n)$ .

### Ordenamiento por Burbuja (Bubble Sort)

- **Descripción:** Bubble Sort es un algoritmo de ordenamiento que compara elementos adyacentes y los intercambia si están en el orden incorrecto. Este proceso se repite hasta que la lista está ordenada.
- **Peor Caso:** El peor caso ocurre cuando los elementos están en orden inverso, lo que obliga al algoritmo a realizar el máximo número de intercambios posibles. En este caso, el tiempo de ejecución es  $O(n^2)$ , ya que el algoritmo realiza aproximadamente  $n$  pasadas completas, y en cada pasada se realizan  $n-1$  comparaciones.

```
def bubble_sort(lista):
    n = len(lista)
    for i in range(n):
        for j in range(0, n-i-1):
            if lista[j] > lista[j+1]:
                lista[j], lista[j+1] = lista[j+1], lista[j] # Intercambio
    return lista

# Ejemplo de uso
lista = [5, 4, 3, 2, 1] # Peor caso: lista en orden inverso
lista_ordenada = bubble_sort(lista)
print("Lista ordenada:", lista_ordenada)
```

En este ejemplo, la lista está inicialmente en orden inverso, lo que representa el peor caso para Bubble Sort. El algoritmo debe realizar el máximo número de intercambios, lo que resulta en un tiempo de ejecución( $n^2$ ).

Estos ejemplos ilustran cómo el análisis del peor caso proporciona una visión crítica del comportamiento de los algoritmos bajo condiciones extremas. La clave es identificar los factores que pueden llevar a estos escenarios y diseñar algoritmos que sean eficientes incluso cuando se enfrentan a ellos.

### 3.4 Comparación con Otros Tipos de Análisis

Es importante contrastar el análisis del peor caso con otros tipos de análisis para entender su valor en el contexto global:

- **Mejor Caso:** Evalúa el escenario más favorable para un algoritmo. Por ejemplo, en la búsqueda lineal, el mejor caso ocurre si el primer elemento es el objetivo, con un tiempo de ejecución  $O(1)$ . Aunque útil, este análisis no proporciona una visión completa del rendimiento del algoritmo bajo condiciones típicas o adversas.
- **Caso Promedio:** Considera el rendimiento esperado en un escenario promedio, ponderando todas las posibles entradas y su probabilidad. Aunque más representativo que el mejor caso, este análisis puede ser complicado de realizar debido a la necesidad de conocer la distribución de las entradas.
- **Peor Caso:** Se enfoca en el rendimiento en el escenario más desfavorable, proporcionando una garantía de que el algoritmo no superará un determinado tiempo de ejecución. Esta certeza es crucial en aplicaciones críticas donde la predictibilidad es esencial.

Unai López de la Fuente (2018) destaca que "Mientras que el análisis del caso promedio es útil en aplicaciones generales, el análisis del peor caso es indispensable en contextos donde la confiabilidad y la estabilidad son fundamentales".

### 3.5 Aplicaciones del Análisis del Peor Caso

El análisis del peor caso tiene aplicaciones prácticas significativas en diversos campos de la informática y la ingeniería de software:



1. **Sistemas en Tiempo Real:** En estos sistemas, es crucial que las operaciones se completen dentro de un límite de tiempo estricto. El análisis del peor caso asegura que el tiempo de ejecución del algoritmo no excederá este límite, garantizando así la estabilidad y seguridad del sistema.
2. **Algoritmos Criptográficos:** En criptografía, es vital que los algoritmos sean resistentes a ataques que intenten explotarlos en sus peores condiciones. El análisis del peor caso ayuda a identificar y reforzar posibles debilidades en estos algoritmos.
3. **Diseño de Base de Datos:** En sistemas de bases de datos, el análisis del peor caso es útil para optimizar consultas y garantizar que las operaciones de búsqueda y recuperación de datos se realicen en un tiempo razonable, incluso con grandes volúmenes de datos.

## 3.6 Conclusión

El análisis del peor caso es una herramienta indispensable en el desarrollo y evaluación de algoritmos, especialmente en aplicaciones donde el rendimiento predecible y la seguridad son críticos. Al enfocarse en el escenario más desfavorable, este tipo de análisis garantiza que los algoritmos sean robustos y puedan manejar condiciones extremas sin fallar.

Cormen et al. (2001) concluyen que "El análisis del peor caso es esencial para diseñar algoritmos que sean fiables y eficientes en cualquier circunstancia, proporcionando una base sólida para el desarrollo de software robusto".

## 4. Análisis del Mejor y Promedio Caso

### 4.1 Introducción al Análisis del Mejor Caso

El análisis del mejor caso evalúa el rendimiento de un algoritmo en la situación más favorable posible. Aunque no es el enfoque más utilizado en la práctica, proporciona información sobre el comportamiento más óptimo de un algoritmo bajo condiciones ideales. Es importante recordar que, aunque el mejor caso pueda ofrecer tiempos de ejecución impresionantemente bajos, rara vez es representativo del rendimiento general de un algoritmo en escenarios del mundo real.

Cormen et al. (2001) señalan que "El análisis del mejor caso ofrece una visión del rendimiento mínimo que se puede esperar de un algoritmo, pero es esencial considerar también otros escenarios para una evaluación completa".

### Ejemplo en Python: Búsqueda Lineal

- **Mejor Caso:** El mejor caso para la búsqueda lineal ocurre cuando el elemento buscado se encuentra en la primera posición de la lista. En este escenario, el algoritmo solo necesita realizar una comparación, lo que resulta en un tiempo de ejecución  $O(1)$ .

```
def busqueda_lineal(lista, objetivo):
    for i in range(len(lista)):
        if lista[i] == objetivo:
            return i # Elemento encontrado
    return -1 # Elemento no encontrado

# Ejemplo de uso
lista = [5, 2, 3, 4, 1] # El objetivo está en la primera posición
objetivo = 5 # Mejor caso
resultado = busqueda_lineal(lista, objetivo)
print("Índice del objetivo:", resultado)
```



## Ejemplo en Python: Ordenamiento por Burbuja (Bubble Sort)

- **Mejor Caso:** El mejor caso para el ordenamiento burbuja ocurre cuando la lista ya está ordenada. En este caso, el algoritmo solo realiza una pasada sin encontrar la necesidad de hacer intercambios, lo que resulta en un tiempo de ejecución  $O(n)$ .

```
def bubble_sort(lista):
    n = len(lista)
    for i in range(n):
        intercambiado = False
        for j in range(0, n-i-1):
            if lista[j] > lista[j+1]:
                lista[j], lista[j+1] = lista[j+1], lista[j] # Intercambio
                intercambiado = True
        if not intercambiado:
            break # Si no hubo intercambios, la lista ya está ordenada
    return lista

# Ejemplo de uso
lista = [1, 2, 3, 4, 5] # Mejor caso: lista ya ordenada
lista_ordenada = bubble_sort(lista)
print("Lista ordenada:", lista_ordenada)
```

En este ejemplo, la lista ya está ordenada, lo que representa el mejor caso para Bubble Sort con un tiempo de ejecución  $O(n)$ , ya que el algoritmo detecta que no se necesitan más intercambios después de la primera pasada.

## 4.2 Introducción al Análisis del Caso Promedio

El análisis del caso promedio evalúa el rendimiento esperado de un algoritmo, considerando una distribución uniforme de todas las posibles entradas. Este análisis es más representativo del comportamiento real de un algoritmo en situaciones cotidianas, ya que pondera todas las entradas posibles y su probabilidad de ocurrencia.

Luis Joyanes Aguilar (2008) subraya que "El análisis del caso promedio es esencial para entender cómo se comportará un algoritmo en la mayoría de los escenarios, proporcionando una estimación más realista de su rendimiento".

El cálculo del caso promedio es más complejo que el del mejor o peor caso, ya que requiere un conocimiento detallado de la distribución de los datos de entrada y cómo se comporta el algoritmo con diferentes entradas.

## Ejemplo en Python: Búsqueda Lineal

- **Caso Promedio:** En el caso promedio, el elemento buscado podría estar en cualquier posición de la lista con igual probabilidad. Si hay  $n$  elementos en la

# Técnicas Avanzadas de Programación

lista, el algoritmo, en promedio, necesitará realizar  $n/2 \cdot n/2 \cdot n/2$  comparaciones. Por lo tanto, el tiempo de ejecución promedio sigue siendo  $O(n)O(n)O(n)$ , aunque la constante es menor que en el peor caso.

```
def busqueda_lineal(lista, objetivo):
    for i in range(len(lista)):
        if lista[i] == objetivo:
            return i # Elemento encontrado
    return -1 # Elemento no encontrado

# Ejemplo de uso
lista = [2, 4, 5, 1, 3]
objetivo = 3 # Caso promedio
resultado = busqueda_lineal(lista, objetivo)
print("Índice del objetivo:", resultado)
```

En este ejemplo, el objetivo (3) está en una posición intermedia, lo que representa un caso promedio en el que el algoritmo tiene que realizar una serie de comparaciones antes de encontrar el objetivo.

## Ejemplo en Python: Ordenamiento por Burbuja (Bubble Sort)

- **Caso Promedio:** En el caso promedio para Bubble Sort, la lista está parcialmente desordenada, lo que significa que el algoritmo realizará múltiples intercambios durante varias pasadas. El tiempo de ejecución promedio se estima en  $n^2$

```
def bubble_sort(lista):
    n = len(lista)
    for i in range(n):
        intercambiado = False
        for j in range(0, n-i-1):
            if lista[j] > lista[j+1]:
                lista[j], lista[j+1] = lista[j+1], lista[j] # Intercambio
                intercambiado = True
        if not intercambiado:
            break # Si no hubo intercambios, la lista ya está ordenada
    return lista

# Ejemplo de uso
lista = [3, 1, 4, 5, 2] # Caso promedio: lista parcialmente desordenada
lista_ordenada = bubble_sort(lista)
print("Lista ordenada:", lista_ordenada)
```

En este ejemplo, la lista está parcialmente desordenada, lo que representa un caso promedio para Bubble Sort con un tiempo de ejecución cercano a  $n^2$ .

## 4.3 Conclusión

El análisis del mejor y caso promedio complementa el análisis del peor caso, proporcionando una visión más completa del rendimiento de un algoritmo. Mientras que el mejor caso muestra el rendimiento óptimo en condiciones ideales, el caso promedio ofrece una estimación más realista del comportamiento del algoritmo en la práctica diaria.

Luis Joyanes Aguilar (2008) concluye que "Aunque el análisis del peor caso es crucial para garantizar la estabilidad y seguridad, el análisis del caso promedio es esencial para entender el rendimiento general de un algoritmo en situaciones del mundo real".

## 5. Otras Notaciones Asintóticas: $\Omega$ y $\Theta$

### 5.1 Introducción a las Notaciones Asintóticas $\Omega$ y $\Theta$

Además de la notación Big O, que describe un límite superior en el tiempo de ejecución de un algoritmo, existen otras notaciones asintóticas importantes que proporcionan una visión más completa de la eficiencia algorítmica: la notación Omega ( $\Omega$ ) y la notación Theta ( $\Theta$ ).

- **Notación Omega ( $\Omega$ ):** La notación  $\Omega$  se utiliza para describir un límite inferior en el tiempo de ejecución de un algoritmo. Es decir, garantiza que el algoritmo no puede ser más rápido que un determinado umbral para grandes valores de  $n$ .
- **Notación Theta ( $\Theta$ ):** La notación  $\Theta$  proporciona una descripción precisa del comportamiento del algoritmo, estableciendo tanto un límite superior como un límite inferior. En otras palabras, describe con exactitud el tiempo de ejecución de un algoritmo para valores grandes de  $n$ .

Según Cormen et al. (2001), "Las notaciones  $\Omega$  y  $\Theta$  completan la triada de notaciones asintóticas al ofrecer una visión integral de la eficiencia de los algoritmos, permitiendo a los desarrolladores comprender tanto el mejor como el peor escenario posible".

### 5.2 Definición Formal de las Notaciones

#### 5.2.1 Notación Omega ( $\Omega$ )

Un algoritmo tiene una complejidad  $\Omega(f(n))$  si existe un número positivo  $c$  y un valor  $n_0$  tal que para todo  $n \geq n_0$ , el tiempo de ejecución  $T(n)$  del algoritmo está acotado por abajo por  $c \cdot f(n)$ .

Formalmente:

$$T(n) \geq c \cdot f(n) \quad \text{para todo } n \geq n_0$$

Esto significa que, en el mejor de los casos, el tiempo de ejecución de un algoritmo será al menos proporcional a  $f(n)$  para grandes valores de  $n$ .

Luis Joyanes Aguilar (2008) destaca que "La notación  $\Omega$  es útil para definir un límite inferior en el comportamiento de un algoritmo, proporcionando una estimación de la mejor eficiencia posible que se puede lograr".

## 5.2.2 Notación Theta ( $\Theta$ )

Un algoritmo tiene una complejidad  $\Theta(f(n))$  si existe un número positivo  $c_1$ ,  $c_2$  y un valor  $n_0$  tal que para todo  $n \geq n_0$ , el tiempo de ejecución  $T(n)$  del algoritmo está acotado tanto por arriba como por abajo por  $c_1 \cdot f(n)$  y  $c_2 \cdot f(n)$ . Formalmente:

$$c_1 \cdot f(n) \leq T(n) \leq c_2 \cdot f(n) \quad \text{para todo } n \geq n_0$$

Esto implica que el tiempo de ejecución del algoritmo es exactamente proporcional a  $f(n)$  para grandes valores de  $n$ , lo que significa que  $f(n)$  describe con precisión el comportamiento del algoritmo.

Unai López de la Fuente (2018) afirma que "La notación  $\Theta$  es la más informativa de las notaciones asintóticas, ya que proporciona una estimación precisa de la eficiencia algorítmica, encapsulando tanto el límite superior como el inferior".

## 5.3 Conclusión

Las notaciones  $\Omega$  y  $\Theta$  complementan la notación Big O, proporcionando una visión más completa y precisa del rendimiento de un algoritmo. Mientras que Big O se enfoca en el límite superior,  $\Omega$  define un límite inferior y  $\Theta$  encapsula tanto el mejor como el peor comportamiento del algoritmo, describiendo su eficiencia con precisión.

Luis Joyanes Aguilar (2008) concluye que "Entender y utilizar las notaciones asintóticas  $\Omega$  y  $\Theta$  permite a los desarrolladores analizar algoritmos de manera más integral, asegurando que se elijan las soluciones más eficientes y adecuadas para cada problema".